

PRESENTACION DE PROYECTO INTEGRADOR

VISION ARTIFICIAL DE APILAMIENTO DE PANALES – EDA & Fase de Preparación y Procesamiento de Datos

PARTE 1:

El EDA en visión por computadora no se centra en medias y desviaciones estándar de columnas, sino en **propiedades visuales de las imágenes** (tamaño, color, calidad, balance de clases, embeddings).

PARTE 2:

La fase de preparación y procesamiento de datos es una de las **más importantes del proyecto**, porque garantiza que los datos estén **limpios, balanceados y preparados** antes de entrenar modelos de IA.

Profesor	Prof. Gladys Villegas, PhD.
Materia	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL – MIAR0545
Alumnos	Francisco Javier Estupiñan Andrade David Alejandro Narváez Mejía
Fecha	09/26/2025

TABLA DE CONTENIDO

1.	INTRODUCCION	4
2.	FLUJOGRAMA DE PROCESO – VISION POR COMPUTADOR	5
3.	EDA EN VISION POR COMPUTADOR	7
3.1	CARGA Y EXPLORACIÓN INICIAL	7
3.2	ANÁLISIS UNIVARIADO (NIVEL IMAGEN)	7
3.3	ANÁLISIS BIVARIADO	7
3.4	ANÁLISIS MULTIVARIADO	7
3.5	DETECCIÓN DE ANOMALÍAS	7
3.6	CONCLUSIONES E INSIGHTS	7
3.7	TABLA EDA DATO VS IMAGEN	7
4.	NOTEBOOK EDA DE VISION POR COMPUTADOR	9
4.1	INTRODUCCIÓN	9
4.2	PREPARACIÓN DEL ENTORNO	9
4.3	CREACIÓN DEL DATASET	9
4.4	VISUALIZACIÓN INICIAL	9
4.5	IMPORTACIÓN DE LIBRERÍAS Y ANÁLISIS	9
4.6	TABLA COMPARATIVA DE MODOS	10
5.	ANALISIS DE RESULTADOS - EDA	11
5.1	EXPLORACIÓN INICIAL	11
5.2	DISTRIBUCIÓN DE CLASES	11
5.3	CORRELACIONES Y PATRONES	11
5.4	DISTRIBUCIONES ANÓMALAS E INCONSISTENCIAS	11
5.5	INSIGHTS PRINCIPALES	12
6.	PIPELINE DE LIMPIEZA DE DATOS	12
6.1	¿POR QUÉ USAR UN PIPELINE?	12
6.2	APLICACIÓN DE PIPELINE EN VISIÓN POR COMPUTADOR	12
7.	ANALISIS DE RESULTADOS – CARACTERISTICAS DE DATOS	13
7.1	PCA DE FEATURES ORIGINALES (SIN BALANCEO)	13

7.2	BALANCEO CON SMOTE.....	13
7.3	PCA DE FEATURES BALANCEADAS	14
7.4	RESULTADOS DEL MODELO BASELINE (RANDOM FOREST)	14
8.	CONCLUSIONES.....	15
9.	REFERENCIAS.....	17

1. INTRODUCCION

La fase de preparación y procesamiento de datos es una de las **más importantes del proyecto**, porque garantiza que los datos estén **limpios, balanceados y preparados** antes de entrenar modelos de IA.

Se centra en:

1. Analizar los datos a fondo (EDA).
2. Detectar y corregir problemas de calidad.
3. Crear nuevas variables (feature engineering).
4. Balancear clases.
5. Aumentar datos con técnicas de *augmentation*.
6. Dividir datos en train/val/test de forma correcta.
7. Construir un pipeline automatizado y reutilizable.

 **Tabla de trabajo – Proyecto Integrador (Apilamiento de Panales)**

Componente	Tareas específicas (apilamiento de panales)	Herramientas / Técnicas sugeridas	Entregables
EDA – Exploratory Data Analysis	- Revisar cantidad de imágenes por clase (OK vs Defecto). - Identificar imágenes duplicadas, corruptas o mal etiquetadas. - Analizar distribución de resoluciones y aspect ratio. - Histogramas de brillo, blur (nitidez) y contraste. - Detectar outliers visuales (panales inclinados, con huecos o sombras extremas). - Revisar balance de clases.	Pandas , Matplotlib , Seaborn . OpenCV , Pillow para métricas de imagen. imagehash para duplicados. t-SNE o PCA para embeddings.	- Notebook con gráficos y estadísticas. - Informe de hallazgos: calidad, balance, anomalías. - Recomendaciones de preprocesamiento.
Pipeline de limpieza de datos	- Crear función que elimine o corrija imágenes corruptas. - Normalizar dimensiones (ej. resize 224×224 con padding). - Estandarizar color (normalización RGB). - Manejar duplicados (remover o consolidar). - Organizar dataset en carpetas train/test/val. - Documentar criterios aplicados.	Clase Python DataCleaner . torchvision.transforms para resize y normalización. Scripts automatizados para dividir dataset.	- Clase DataCleaner implementada. - Carpeta dataset/ limpia y organizada. - Reporte con criterios de limpieza aplicados.
Feature Engineering	- Extraer histogramas de color y texturas (HOG, LBP) como baseline. - Obtener embeddings de modelos preentrenados (ResNet18, MobileNetV2). - Generar variables derivadas (alineación de bordes, número de gaps). - Seleccionar características más relevantes (ej. importancia con Random Forest).	scikit-image (HOG, LBP). torchvision.models (ResNet, MobileNetV2). sklearn (PCA, selección de features, importancia con Random Forest).	- Dataset enriquecido con features. - Notebook con extracción de características. - Tabla comparativa (baseline vs embeddings). - Recomendación de features finales.

Tabla 3: EDA / FUENTE: Generado ChatGPT

 **Tabla de trabajo – Proyecto Integrador (Apilamiento de Panales) – Parte 2**

Componente	Tareas específicas (apilamiento de panales)	Herramientas / Técnicas sugeridas	Entregables
Balanceo de datos	- Medir el desbalance entre clases (OK vs Defecto). - Visualizar proporción de clases con gráficos de barras/pie. - Aplicar técnicas de oversampling si hay pocos defectos (SMOTE, ADASYN). - Probar undersampling en la clase mayoritaria. - Evaluar técnicas híbridas (SMOTEENN, SMOTETomek). - Comparar métricas antes y después del balanceo.	imbalanced-learn (SMOTE, ADASYN, Tomek Links). scikit-learn para métricas y validación. EDA visual con Matplotlib/Seaborn .	- Reporte con métricas de desbalance. - Dataset balanceado. - Comparación de rendimiento del modelo pre y post balanceo.
Data Augmentation	- Diseñar augmentations específicas para imágenes de panales: • Rotación leve ($\pm 10^\circ$). • Flips horizontales/verticales. • Cambios de brillo y contraste. • Adición de ruido leve. - Validar que los augmentations sean realistas y no generen ejemplos confusos. - Integrar augmentations al pipeline de entrenamiento.	torchvision.transforms (RandomRotation , RandomHorizontalFlip , ColorJitter). albumentations para técnicas más avanzadas. Visualización de ejemplos antes/después.	- Notebook con visualización de augmentations. - Carpeta con imágenes aumentadas (opcional). - Informe sobre impacto en el modelo (mejora de generalización).
Partición Estratificada de Datos	- Dividir dataset en train (70%), validation (15%), test (15%). - Usar estratificación para mantener la misma proporción de clases en cada subset. - Validar que no haya data leakage (ej. la misma imagen en train y test). - Verificar representatividad de cada subset (misma distribución de defectos). - Preparar función automática para futuras divisiones.	sklearn.model_selection.StratifiedShuffleSplit . train_test_split con stratify . Scripts de control con hashlib para verificar duplicados en splits.	- Carpeta dataset/ con subcarpetas train/val/test. - Notebook con validación de particiones. - Reporte de distribución de clases en cada subset.

Tabla 4: PREPARACION DE DATOS / FUENTE: Generado ChatGPT

2. FLUJOGRAMA DE PROCESO – VISION POR COMPUTADOR



Figura 1: Proceso de proyectos Visión por Computador / FUENTE: Machine-Vision-Systems-Design A3 VISION

El flujo de proceso para el diseño e implementación de un proyecto de visión por computador, tiene la siguiente **descripción paso a paso** que acompañará al diagrama “Typical Design Sequence”:

1. Definir el tipo de sistema de visión (MV)
 - Propósito: elegir la arquitectura general (smart camera, cámara atada a controlador, PC-based).
 - Entradas: objetivos de calidad, tasa de producción, espacio disponible, presupuesto, integración con PLC/robot.
 - Salidas: arquitectura elegida, cantidad de cámaras, esquema de disparo (trigger) y sincronización.
 - Nota proyecto: si hay varias vistas o alta complejidad (mediciones y ML), suele convenir **PC-based** por flexibilidad.
2. Seleccionar la(s) cámara(s)
 - Definir **campo de visión (FOV)** con margen (10–20% de overscan).
 - Calcular **resolución espacial** requerida (mm/px) a partir del tamaño mínimo a medir y los “píxeles que deben abarcar la característica”.
 - Validar **velocidad** (fps y tiempo de exposición para que el desenfoque por movimiento ≤ 1 px), **obturador** (global preferible), **interfaz** (GigE/USB3/CoaXPress).
 - Salidas: modelo de cámara, resolución, fps, obturador, interfaz.
 - Nota proyecto: si la línea se mueve rápido, priorizar **global shutter** y exposición corta.
3. Seleccionar el lente
 - Calcular magnificación (sensor/FOV) y distancia de trabajo.
 - Elegir focal que cumpla el FOV en la distancia real y resolución óptica $\geq$ a la frecuencia de Nyquist del pixel.
 - Verificar montura (C/CS/S) y distorsión aceptable; considerar telecéntrico si la precisión dimensional es crítica.
 - Salidas: focal, distancia de trabajo, montura, requisitos de resolución óptica.
4. Verificar cámara & lente
 - Prueba en banco: enfocar al FOV objetivo, medir **distancia de trabajo**, chequear **resolución** en centro y esquinas con diana, revisar **distorsión**.
 - Criterio de salida: se cumplen FOV, nitidez y resolución en todo el campo.
5. Seleccionar la técnica/fuente de iluminación
 - Partir de la **característica que necesita contraste** (bordes de panales, alineación, huecos, etc.).
 - Elegir **geometría** (backlight para siluetas, front light difusa/oscura/brillante), **difusividad**, **longitud de onda**, **polarización**, y si será **continua o estroboscópica**.
 - Salida: modelo y geometría de iluminación + fijación mecánica.

- Nota proyecto: para contorno y gaps, un **backlight difuso** suele dar siluetas limpias; si debes ver textura/superficie, front-light difusa.
6. Verificar la imagen (imaging)
 - Montaje preliminar: capturar lote de muestras representativas.
 - Revisar **exposición, uniformidad, contraste, reflejos, sombras y SNR**; ajustar ángulos/altura/ganancia.
 - **Integrar EDA de imágenes** aquí: histogramas de brillo, blur (var. del Laplaciano), distribución de tamaños, balance de clases, duplicados (pHash), outliers.
 - Salidas: parámetros finales de cámara/iluminación y **plan de normalización** (resize, recorte, normalización RGB) + **plan de augmentation** según variabilidad real.
 7. Diseñar el procesamiento de imagen
 - Definir **pipeline** a partir del EDA y requisitos:
 1. Preprocesado (resize/padding, normalización, reducción de ruido).
 2. Localización/segmentación (bordes, umbrales adaptativos, morfología, o modelo CNN/Detección).
 3. Cálculos/medidas (alineación, separaciones, conteo, reglas geométricas).
 4. Clasificación OK/Defecto o métricas de calidad.
 - Elegir herramientas (clásicas vs. **CNN/CNN+Transformers**) en función de la separabilidad observada en el EDA (embeddings/PCA).
 - Definir **KPIs de desempeño** (precisión, recall, F1, tiempo de ciclo) y protocolo de pruebas (FAT).
 - Salidas: diagrama de bloques, parámetros iniciales, dataset curado y dividido (train/val/test).
 8. Implementar
 - Integración con **PLC/robot/HMI**, triggers, protocolos (EtherNet/IP, Profinet, etc.).
 - Calibraciones requeridas (intrínseca; mano-ojo si hay robot y medidas en mm).
 - Construcción mecánica, cableado, seguridad, receta de producto.
 - Pruebas funcionales: **FAT** (en taller) con criterios aceptados (tasas de falsos ± máximas, tiempos de ciclo).
 9. Desplegar
 - Instalación, **SAT** (en planta), validación en producción, capacitación a operadores/mantenimiento.
 - Entrega de **documentación** (parámetros, planos, backups, manuales) y **plan de soporte**.
 - Estrategia de **monitoreo y mejora continua** (log de imágenes, re-entrenos, umbrales adaptativos, mantenimiento de iluminación/cámara).

3. EDA EN VISION POR COMPUTADOR

El EDA en visión por computadora no se centra en medias y desviaciones estándar de columnas, sino en **propiedades visuales de las imágenes** (tamaño, color, calidad, balance de clases, embeddings).

3.1 CARGA Y EXPLORACIÓN INICIAL

Revisar estructura del dataset:

- ✓ Número total de imágenes.
- ✓ Número de clases (si es clasificación).
- ✓ Cantidad de imágenes por clase (balance/desbalance).

Ver ejemplos de imágenes de cada clase para validar calidad y coherencia.

Revisar tamaños y formatos (JPG, PNG, resoluciones).

3.2 ANÁLISIS UNIVARIADO (NIVEL IMAGEN)

Dimensiones: histogramas de ancho, alto y proporción (aspect ratio).

Distribución de colores: histograma de valores RGB o escala de grises.

Tamaño de archivo: ver si hay mucha variación.

Calidad: detectar imágenes borrosas, muy oscuras o sobreexpuestas.

3.3 ANÁLISIS BIVARIADO

Comparar características de las imágenes con sus etiquetas:

- ✓ Número de imágenes por clase → detectar desbalance.
- ✓ Relación entre tamaño de la imagen y la clase.
- ✓ Variación de color promedio por clase (ejemplo: panales vs jarras podrían tener gamas distintas).

3.4 ANÁLISIS MULTIVARIADO

Reducción de dimensionalidad:

- ✓ Extraer embeddings con un modelo preentrenado (ejemplo: ResNet, MobileNet).
- ✓ Usar PCA o t-SNE para visualizar cómo se agrupan las clases en 2D/3D.

Detectar si las clases están bien separadas visualmente o si hay mucho solapamiento.

3.5 DETECCIÓN DE ANOMALÍAS

Imágenes duplicadas.

Imágenes mal etiquetadas (ej. un panal en la clase "barril").

Imágenes vacías, corruptas o con ruido.

Variaciones extremas en iluminación, fondo o perspectiva.

3.6 CONCLUSIONES E INSIGHTS

Identificar si se necesita:

- ✓ Balancear clases (data augmentation o recolección de más datos).
- ✓ Normalizar tamaños (redimensionar todas a 224x224, por ejemplo).
- ✓ Mejorar calidad (filtrar imágenes borrosas).
- ✓ Preprocesamiento de color (normalización de canales RGB).

3.7 TABLA EDA DATO VS IMAGEN

En datos tabulares, el EDA se centra en estadísticas, correlaciones y valores faltantes.

En imágenes, el EDA se centra en calidad visual, balance de clases, propiedades de color/forma y en detectar anomalías visuales.

El punto común es que ambos buscan preparar los datos para un modelo de IA robusto.

Aspecto	EDA en Datos Tabulares (numéricos/catégoricos)	EDA en Imágenes (visión por computador)	Qué se contrasta
Estructura del dataset	Número de filas y columnas, tipos de variables (int, float, catégoricas, fechas)	Número total de imágenes, número de clases, formato (JPG, PNG, TIFF), dimensiones (alto × ancho)	Tamaño y consistencia del dataset
Valores faltantes / corruptos	Detección de NaN , duplicados, registros incompletos	Imágenes corruptas, vacías, duplicadas (hash), ilegibles	Calidad y completitud de la información
Balance de clases	Conteo de catégorías (ej. hombres vs mujeres, aprobado vs reprobado)	Número de imágenes por clase (OK vs Defecto), desbalance de clases	Distribución equitativa de etiquetas
Estadísticas univariadas	Media, mediana, moda, desviación estándar, rangos	Histograma de brillo, color (RGB, HSV), tamaños de imagen, blur (nitidez)	Distribución de valores/características
Outliers	Detección por IQR, Z-score, clustering	Imágenes atípicas (muy oscuras, sobreexpuestas, con ruido, mal encuadre)	Consistencia y representatividad
Correlaciones	Matriz de correlación (Pearson, Spearman) entre variables	Relación entre atributos visuales y clases (ej. color medio vs clase)	Variables relevantes para predicción
Multivariable / Reducción de dimensionalidad	PCA, t-SNE, clustering de variables	PCA/t-SNE sobre embeddings (CNN preentrenada) para ver agrupamiento de imágenes por clase	Separabilidad entre clases
Temporalidad (si aplica)	Series de tiempo, estacionalidad, tendencias	Secuencias de video, patrones de movimiento	Análisis de patrones en el tiempo
Conclusiones	Identificar variables clave, preparar limpieza y normalización 	Identificar preprocesamiento: resize, normalización de color, augmentations necesarias	Recomendaciones para el modelo de IA

Tabla 1: Comparativa de dato vs imagen / FUENTE: Generado ChatGPT

4. NOTEBOOK EDA DE VISION POR COMPUTADOR

Este notebook busca enseñar paso a paso cómo realizar un **Análisis Exploratorio de Datos (EDA)** para datasets de **visión por computador**, integrando diferentes modos (clasificación, detección y segmentación).

Los ítems son:

1. **Organizar datasets** de forma estandarizada.
2. **Visualizar imágenes y etiquetas** para detectar errores o anomalías.
3. **Aplicar métricas descriptivas** que orienten la fase de preprocesamiento y modelado.

4.1 INTRODUCCIÓN

El notebook se titula EDA de Visión por Computador — Multiformato y corresponde al proyecto integrador de la maestría.

Explica que el análisis exploratorio de datos (EDA) soporta tres tipos de tareas en visión por computador:

Clasificación: imágenes organizadas en carpetas por clase (clase_a, clase_b, ...).

Detección (YOLO): imágenes con anotaciones en formato .txt (coordenadas normalizadas).

Segmentación: imágenes y máscaras binarias o multiclase en formato .png.

Las librerías principales son: `numpy`, `pandas`, `matplotlib`, `opencv-python`, y `Pillow`.

4.2 PREPARACIÓN DEL ENTORNO

Incluye la opción de montar Google Drive (en caso de usar Google Colab).

Define rutas a los datasets y verifica qué clases están disponibles.

Se genera una estructura 20/80 para entrenamiento y validación, asegurando que los datos estén balanceados y limpios.

4.3 CREACIÓN DEL DATASET

Se eliminan datasets previos si existen (limpieza).

Se crean nuevas carpetas para train y test.

Se implementa una función para copiar imágenes, dividir las según proporción definida y validar la consistencia.

4.4 VISUALIZACIÓN INICIAL

Se muestra un ejemplo de imágenes por clase usando matplotlib.

Cada clase se representa con una imagen de muestra, lo que permite verificar:

- ✓ Calidad visual.
- ✓ Diferencias entre categorías.
- ✓ Posibles inconsistencias en el dataset.

4.5 IMPORTACIÓN DE LIBRERÍAS Y ANÁLISIS

En secciones posteriores (según el índice detectado), se importan librerías adicionales para:

- ✓ **EDA cuantitativo:** conteo de imágenes por clase, tamaños de archivo, dimensiones.
- ✓ **EDA visual:** histogramas, distribución de proporciones train/test, ejemplos de bounding boxes (detección) y máscaras (segmentación).

4.6 TABLA COMPARATIVA DE MODOS

 **Tabla descriptiva de modos de dataset en visión por computador**

Modo	Estructura de carpetas	Qué contiene	Análisis EDA aplicado	Aplicación en proyecto (apilamiento de panel)
Clasificación	<code>data/clase_a/*.jpg</code> , <code>data/clase_b/*.jpg</code>	Imágenes divididas en carpetas según clase (ej. OK vs Defecto)	- Conteo de imágenes por clase (balance/desbalance). - Distribución de tamaños y resoluciones. - Histogramas de brillo y blur. - Detección de duplicados (pHash). - Outliers (imágenes borrosas o sobreexpuestas).	Útil para un modelo CNN de clasificación que de paneles es correcto o incorrecto.
Detección (YOLO)	<code>data/images/*.jpg</code> <code>data/labels/*.txt</code> <code>classes.txt</code> (opcional)	Imágenes y anotaciones <code>.txt</code> con bounding boxes normalizados (<code>class x y w h</code>).	- Distribución de objetos por imagen. - Conteo de clases en etiquetas. - Histogramas de tamaño relativo de bounding boxes. - Validación de etiquetas (coordenadas dentro de [0,1]). - Visualización con cajas dibujadas.	Útil si quieres localizar defectos específicos (ej. huecos en la pila). El sistema no solo clasifica, también está el error.
Segmentación	<code>data/images/*.jpg</code> <code>data/masks/*.png</code>	Imágenes y sus máscaras (por píxel) indicando regiones de interés.	- Cobertura de máscaras (proporción de píxeles etiquetados). - Distribución de cobertura (outliers: máscaras casi vacías o casi llenas). - Correspondencia 1:1 imagen ↔ máscara. - Validación de duplicados, blur y brillo.	Permite entrenar un modelo de segmentación identifique zona por zona si los paneles están o si hay anomalías en la superficie.

Tabla 2: Comparativa de modos / FUENTE: Generado ChatGPT

5. ANALISIS DE RESULTADOS - EDA

Exploración inicial

Totál de imágenes: 80

	filepath	label	width	height	aspect_ratio	file_size	mean_r	mean_g	mean_b	brightness	blur_var	phash
0	/content/drive/MyDrive/Proyecto Final Maestría...	NG_tipo1	640	640	1.0	50761	176.354778	165.320883	155.790180	164.765481	32.886087	None
1	/content/drive/MyDrive/Proyecto Final Maestría...	NG_tipo1	640	640	1.0	61072	176.718542	166.378843	150.724167	167.879995	34.523157	None
2	/content/drive/MyDrive/Proyecto Final Maestría...	NG_tipo1	640	640	1.0	60847	177.415769	166.430310	156.969680	168.086330	32.723040	None
3	/content/drive/MyDrive/Proyecto Final Maestría...	NG_tipo1	640	640	1.0	61135	173.085286	163.162036	164.642200	164.842448	46.404414	None
4	/content/drive/MyDrive/Proyecto Final Maestría...	NG_tipo1	640	640	1.0	60574	173.334446	163.868684	154.643420	165.215541	35.125552	None

	filepath	label	width	height	aspect_ratio	file_size	mean_r	mean_g	mean_b	brightness	blur_var	phash
count	80	80	80.000000	80.0	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	0
unique	80	6	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	6
top	/content/drive/MyDrive/Proyecto Final Maestría...	OK_tipo2	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
freq	1	20	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
mean	NaN	NaN	638.000000	640.0	0.996875	86449.975000	155.225302	149.080875	143.879747	149.956844	58.315951	NaN
std	NaN	NaN	17.805544	0.0	0.027951	33979.764564	27.718034	16.973453	14.667806	18.250129	40.139051	NaN
min	NaN	NaN	486.000000	640.0	0.750000	41512.000000	73.058628	106.734712	117.796089	101.971209	11.404858	NaN
25%	NaN	NaN	640.000000	640.0	1.000000	58791.000000	149.001732	136.040843	126.678057	137.564281	31.041429	NaN
50%	NaN	NaN	640.000000	640.0	1.000000	62497.000000	167.596695	157.508791	150.324877	159.268067	40.736577	NaN
75%	NaN	NaN	640.000000	640.0	1.000000	124930.750000	172.230848	163.512297	164.993022	164.810960	93.180066	NaN
max	NaN	NaN	640.000000	640.0	1.000000	142990.000000	179.105995	168.261582	160.398087	170.823209	157.062779	NaN

Matriz de correlación

	width	height	aspect_ratio	file_size	mean_r	mean_g	mean_b	brightness	blur_var
width	1.000000	NaN	NaN	1.000000	0.149728	-0.097725	-0.128042	-0.133753	-0.124486
height	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
aspect_ratio	1.000000	NaN	1.000000	0.149728	-0.097725	-0.128042	-0.133753	-0.124486	0.035331
file_size	0.149728	NaN	0.149728	1.000000	-0.719998	-0.876641	-0.735850	-0.858303	0.896849
mean_r	-0.097725	NaN	-0.097725	-0.719998	1.000000	0.912014	0.258419	0.944540	-0.731635
mean_g	-0.128042	NaN	-0.128042	-0.876641	0.912014	1.000000	0.627783	0.996088	-0.778995
mean_b	-0.133753	NaN	-0.133753	-0.735850	0.258419	0.627783	1.000000	0.559054	-0.479143
brightness	-0.124486	NaN	-0.124486	-0.858303	0.944540	0.996088	0.559054	1.000000	-0.782213
blur_var	0.035331	NaN	0.035331	0.896849	-0.731635	-0.778995	-0.479143	-0.782213	1.000000





Figura 2: Resultados de NOTEBOOK / FUENTE: Notebook grupo 4
Vision_Computador_Grupo_4_Rev_5_EDA.ipynb

5.1 EXPLORACIÓN INICIAL

El dataset analizado consta de 80 imágenes etiquetadas en seis clases (OK y NG con tres subtipos cada una). Cada imagen presenta resolución uniforme de 640x640 píxeles, con atributos asociados a dimensiones, tamaño de archivo, valores medios de canales RGB, brillo promedio y nivel de desenfoque (blur_var). El análisis inicial muestra que las dimensiones no aportan variación, dado que el aspecto geométrico permanece constante en todas las instancias.

5.2 DISTRIBUCIÓN DE CLASES

El conteo por clases revela un desbalance significativo: mientras las clases OK_tipo1 y OK_tipo2 cuentan con 20 ejemplos cada una, las clases NG sólo contienen 8 ejemplos por subtipo. Esta situación puede sesgar los modelos predictivos hacia clasificar preferentemente la categoría mayoritaria. Se recomienda aplicar técnicas de balanceo como data augmentation en las clases minoritarias, o estrategias de oversampling.

5.3 CORRELACIONES Y PATRONES

La matriz de correlación evidencia relaciones fuertes entre las variables de color (mean_r, mean_g, mean_b) y el brillo, lo que confirma redundancia de información cromática. Asimismo, el tamaño de archivo presenta alta correlación positiva con el brillo y negativa con el desenfoque. Este hallazgo sugiere que imágenes más nítidas tienden a ser menos luminosas y ocupar menor espacio de almacenamiento. Estas dependencias deben ser consideradas en la selección de características, evitando colinealidad y favoreciendo técnicas de reducción de dimensionalidad como PCA.

5.4 DISTRIBUCIONES ANÓMALAS E INCONSISTENCIAS

El análisis descriptivo muestra variabilidad en el brillo y en el desenfoque. En particular, la variable blur_var evidencia casos de imágenes con alto nivel de desenfoque, lo cual puede impactar negativamente en la calidad del entrenamiento. La estandarización de la iluminación mediante normalización de histogramas y la eliminación o filtrado de imágenes excesivamente borrosas resultan pasos recomendables para fortalecer el dataset.

5.5 INSIGHTS PRINCIPALES

- ✓ El dataset presenta un desbalance de clases que debe ser corregido.
- ✓ Las variables cromáticas (RGB y brillo) son redundantes y pueden generar colinealidad.
- ✓ El desenfoque constituye un indicador relevante para diferenciar defectos (NG).
- ✓ La variabilidad de iluminación introduce ruido y debe ser mitigada con técnicas de normalización.

6. PIPELINE DE LIMPIEZA DE DATOS

En **inteligencia artificial y ciencia de datos**, un **pipeline** es una **secuencia ordenada de pasos** (transformaciones, limpiezas, normalizaciones, etc.) que se aplican automáticamente a los datos desde que los recibes hasta que están listos para entrenar un modelo.

Es como una **línea de producción en una fábrica**:

- ✓ Entrás con materia prima (datos crudos).
- ✓ Pasan por distintas máquinas (etapas del pipeline): limpieza, transformación, escalado, codificación.
- ✓ Sales con un producto terminado (datos listos para el modelo de IA).

6.1 ¿POR QUÉ USAR UN PIPELINE?

Automatización → No repites manualmente cada paso, se ejecuta en cadena.

Reproducibilidad → Garantiza que los mismos pasos se aplican siempre, evitando errores humanos.

Trazabilidad → Cada etapa queda documentada (qué se limpió, qué se transformó).

Integración con modelos → En librerías como *scikit-learn*, el pipeline se entrena y transforma los datos junto al modelo, asegurando consistencia en entrenamiento y predicción.

Escalabilidad → Puedes aplicarlo en datasets grandes o en producción sin modificar código.

6.2 APLICACIÓN DE PIPELINE EN VISIÓN POR COMPUTADOR

Supongamos tu proyecto de **apilamiento de panales**:

1. **Carga de imágenes.**
2. **Limpieza** (remover duplicadas, corruptas).
3. **Preprocesamiento** (resize a 224×224, normalizar valores de píxeles).
4. **Data augmentation** (rotar, reflejar, variar brillo).
5. **Extracción de características** (CNN preentrenada → embeddings).
6. **Entrenamiento del modelo** (clasificación OK/Defecto).

Todo esto se encadena en un **pipeline** → cada vez que ingresa una nueva imagen, pasa automáticamente por todos los pasos.

7. ANALISIS DE RESULTADOS – CARACTERISTICAS DE DATOS

El pipeline de limpieza + features + SMOTE mejoró el balance de datos y permitió entrenar un modelo baseline justo.




Figura 6: Resultados de NOTEBOOK / FUENTE: Notebook grupo 4
Vision_Computador_Grupo_4_Rev_6_TRAIN.ipynb

7.1 PCA DE FEATURES ORIGINALES (SIN BALANCEO)

El primer gráfico (PCA inicial) muestra cómo las features extraídas (color, HOG, etc.) se distribuyen en 2D.

Observamos:

- ✓ Clases OK_tipo y NG_tipo aparecen, pero con cierta mezcla y desequilibrio en cantidad.
- ✓ Hay grupos compactos (ej. OK_tipo2) y otros más dispersos (NG_tipo1, NG_tipo2).

Esto indica que las clases no estaban balanceadas, y algunas tenían menos muestras, lo que afecta al modelo en su capacidad de aprender de forma justa.

7.2 BALANCEO CON SMOTE

El log indica que SMOTE generó 25 muestras sintéticas por clase, equilibrando NG_tipo1, NG_tipo2, NG_tipo3, OK_tipo1, OK_tipo2, OK_tipo3.

Con esto, todas las clases quedan representadas en la misma magnitud → se evita que el modelo prefiera la clase mayoritaria.

7.3 PCA DE FEATURES BALANCEADAS

En el gráfico posterior al balanceo, cada clase aparece con un número similar de puntos.

Aunque SMOTE genera puntos sintéticos en el espacio de características (no imágenes nuevas), visualmente observamos:

- ✓ Mayor uniformidad en la nube de datos.
- ✓ Las clases se ven más “niveladas”, y ya no hay clases con 3–4 muestras frente a otras con decenas.

Esto facilita que el modelo aprenda fronteras de decisión más equilibradas.

7.4 RESULTADOS DEL MODELO BASELINE (RANDOM FOREST)

El reporte de clasificación muestra:

- ✓ Accuracy global ≈ 0.85 (muy bueno para un baseline).
- ✓ Clases como OK_tipo2 y OK_tipo3 obtienen recall y precisión altos (0.90+).
- ✓ Clases NG_tipo1 y NG_tipo2 tienen recall = 0.50: el modelo reconoce bien algunos positivos, pero aún le cuesta captarlos todos.

Esto es esperable porque:

- ✓ Aunque SMOTE balancea, las clases NG tenían muy pocos ejemplos reales → los sintéticos no siempre capturan toda la variabilidad.
- ✓ El baseline es un modelo simple (Random Forest sobre features tabulares), sin optimización.

8. CONCLUSIONES




Figura 3: Resultados de NOTEBOOK / FUENTE: Notebook grupo 4
Vision_Computador_Grupo_4_Rev_5_EDA.ipynb

El análisis exploratorio permite concluir que el dataset, aunque útil como base experimental, requiere ajustes para su uso efectivo en entrenamiento de modelos de clasificación. La corrección del desbalance, la reducción de colinealidad y la normalización de condiciones de iluminación resultan prioritarias para garantizar un modelo robusto y generalizable. Este EDA constituye una etapa crítica que orienta el diseño de los siguientes pasos en el pipeline de visión por computador.





Figura 4: Resultados de NOTEBOOK / FUENTE: Notebook grupo 4
Vision_Computador_Grupo_4_Rev_5_EDA.ipynb

El dataset de segmentación presenta una estructura clara y bien definida, lo que facilita su aplicación en modelos como U-Net o Mask R-CNN. Sin embargo, la variabilidad en desenfoque y las limitaciones en iluminación deben ser tratadas con técnicas de normalización y data augmentation. Este análisis confirma la utilidad del dataset para investigaciones académicas, destacando la importancia de un preprocesamiento cuidadoso antes del entrenamiento.



*Figura 5: Resultados de NOTEBOOK / FUENTE: Notebook grupo 4
Vision_Computador_Grupo_4_Rev_6_TRAIN.ipynb*

Antes de balancear, el dataset estaba desbalanceado, lo cual sesgaba al modelo hacia clases mayoritarias. SMOTE equilibró la distribución de clases, generando ejemplos sintéticos en el espacio de features. El PCA balanceado confirma que todas las clases quedaron mejor representadas en el espacio de características. El modelo baseline muestra una buena precisión global, pero el recall bajo en NG advierte que aún hay dificultad para detectar defectos, algo común en datasets con pocos negativos reales.

Próximos pasos, aplicar data augmentation real sobre imágenes (rotación, iluminación, ruido) para mejorar la variabilidad de NG. Probar un modelo más robusto (CNN o fine-tuning de ResNet) en lugar de solo Random Forest con HOG+Color. Ajustar hiperparámetros y usar validación cruzada estratificada.

9. REFERENCIAS

- [1] N. Hütten, A. et al., “Deep Learning for Automated Visual Inspection in Industrial Applications,” *Machines*, vol. 12, no. 1, p. 11, Jan. 2024.
- [2] S. Arikan, K. Varanasi, and D. Stricker, “Surface Defect Classification in Real-Time Using Convolutional Neural Networks,” *arXiv preprint*, arXiv:1904.04671, 2019.
- [3] M. Jalayer, R. Jalayer, A. Kaboli, C. Orsenigo, and C. Vercellis, “Automatic Visual Inspection of Rare Defects: A Framework based on GP-WGAN and Enhanced Faster R-CNN,” *arXiv preprint*, arXiv:2105.00447, 2021.
- [4] T. Defard, A. Setkov, A. Loesch, and R. Audigier, “PaDiM: a Patch Distribution Modeling Framework for Anomaly Detection and Localization,” *arXiv preprint*, arXiv:2011.08785, 2020.
- [5] T. Schlosser, F. Beuth, M. Friedrich, and D. Kowerko, “A Novel Visual Fault Detection and Classification System for Semiconductor Manufacturing Using Stacked Hybrid Convolutional Neural Networks,” *arXiv preprint*, arXiv:1911.11250, 2019.
- [6] J. Villalba-Diez et al., “Deep Learning for Industrial Computer Vision Quality,” *Sensors*, vol. 19, no. 22, pp. 4780, Nov. 2019.
- [7] A. Wan et al., “Deep learning-based intelligent visual inspection for defect detection in smoke sensor manufacturing,” *Engineering Applications of Artificial Intelligence*, vol. 142, p. 107004, Jan. 2025.
- [8] J. Huang, “Automated Logistics Packaging Inspection Based on Deep Learning and Computer Vision: A Two-Dimensional Flow Model Approach,” *Traitement du Signal*, vol. 42, no. 2, pp. 275–282, 2025.
- [9] “Advancing industrial inspection with an automated visual inspection tool powered by computer vision,” *Scientific Reports*, vol. 15, art. no. 88974, Feb. 2025.
- [10] C. D. Hollander, S. Das, and S. Suliman, “Automating Visual Inspection with Convolutional Neural Networks,” in *Proc. PHM Society Conf.*, 2019, pp. 868–875.
- [11] S. Yadav and R. Kennedy, “Vision Inspection Using Machine Learning/Artificial Intelligence,” *Pharmaceutical Engineering*, Nov. 2020.
- [12] R. A. León, et al., “Design of an artificial vision algorithm to detect cracks in construction,” in *Proc. LACCEI Int. Conf.*, Buenos Aires, 2023, pp. 1–9.
- [13] O. Barahona, “Design and Implementation of an Artificial Vision System for Defect Detection,” *KnE Engineering*, 2022.
- [14] M. C. Nava, “CNN computer for high-speed visual inspection,” in *Proc. SPIE 4301, VLSI Circuits and Systems*, 2001.
- [15] M. E. A. Macías et al., “Design and simulation of an artificial vision sorting machine and cocoa pulping machine,” *Ciencia Latina*, vol. 6, no. 3, pp. 1456–1468, 2022.
- [16] T. Defard et al., “Anomaly detection in industrial applications with deep learning,” *arXiv preprint*, arXiv:2011.08785, 2020.
- [17] M. Jalayer et al., “Faster R-CNN with synthetic data generation for rare defect inspection,” *arXiv preprint*, arXiv:2105.00447, 2021.
- [18] J. Huang, “Deep learning for logistics packaging inspection,” *Traitement du Signal*, vol. 42, no. 2, pp. 275–282, 2025.
- [19] J. Villalba-Diez et al., “Deep Learning for Industrial Quality Control,” *Sensors*, vol. 19, no. 22, pp. 4780, 2019.
- [20] A. Wan et al., “Visual inspection with DL in sensor manufacturing,” *Eng. Appl. Artif. Intell.*, vol. 142, p. 107004, 2025.
- [21] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 3rd ed. O'Reilly Media, 2022.

- [22] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA: MIT Press, 2016.
- [23] J. C. Cuevas-Tello, "Apuntes de Redes Neuronales Artificiales," arXiv preprint, arXiv:1806.05298, 2018.
- [24] S. Soatto, Foundations of Computer Vision (Adaptive Computation and Machine Learning series). Cambridge, MA: MIT Press, 2024.
- [25] D. Forsyth and J. Ponce, Computer Vision: A Modern Approach, 2nd ed. Pearson, 2011.
- [26] Y. Goldberg, Neural Network Methods for Natural Language Processing. Morgan & Claypool, 2017.
- [27] F. Pasquale, Las nuevas leyes de la robótica. Madrid: Ediciones Paidós, 2024.